석사학위논문

LiDAR 기반 객체 탐지의 정밀도 향상을 위한 적응형 Voxel화 기법

Adaptive Voxelization Techniques for Improved Precision in LiDAR-Based Object Detection

고 대 권

한양대학교 대학원

2025년 2월

석사학위논문

LiDAR 기반 객체 탐지의 정밀도 향상을 위한 적응형 Voxel화 기법

Adaptive Voxelization Techniques for Improved Precision in LiDAR-Based Object Detection

지도교수 박 장 현

이 논문을 공학 석사학위논문으로 제출합니다.

2025년 2월

한양대학교 대학원

미래자동차공학과

고 대 권

이 논문을 고대권의 석사학위 논문으로 인준함

2025년 2월

심 사 위 원 장 : 조 기 춘 (인)

심 사 위 원 : 이 동 진 (인)

심 사 위 원 : 박 장 현 (인)

한양대학교 대학원

차 례

차 례 ····· i

그림 목차 ····· iii

표 목차 ····· iii

국문 요지 ····· iv

제1장 서 론 ····· 1
1.1 연구 배경 ····· 1
1.2 최신 CNN 연구 동향 ····· 2
1.3 연구 목표 ····· 4
1.4 연구 내용 ····· 5

제 2장 관련 연구 ····· 6
2.1 Voxel-based model ····· 6
2.2 Pillar-based model ····· 7
2.3 Dynamic Voxelization ····· 8

제 3장 기법 제안 ····· 10
3.1 Self-Adaptive Voxelization ····· 10
3.2 Self-Adaptive Voxelization 공식 적용 ····· 13
3.3 Scaling Factor 조정 기준 ····· 16
3.4 Pillar에서의 Self-Adaptive Voxelization ····· 19

제 4장 실험 구성 및 진행 ····· 21
4.1 실험 환경 ····· 21
4.1.1 KITTI Dataset ····· 21
4.1.2 MMDetection3D ····· 22
4.2 실험 설정 ····· 23
4.3 실험 결과 ····· 23
4.3.1 KITTI Dataset – 3D Object Detection Visualization ····· 24
4.3.2 KITTI Dataset – Average Precision Result ····· 27

제 5장 결 론 ····· 30
5.1 결과 고찰 및 분석 ····· 30
5.2 추후 연구 ····· 31

참고 문헌 ····· 32

Abstract ····· 35

감사의 글 ····· 37

그림 목차

Fig 1. ConvNeXt block modification ····· 3
Fig 2. Voxel-based model Encoder Architecture ····· 6
Fig 3. Pillar-based model Encoder Architecture ····· 7
Fig 4. Dynamic Voxelization Algorithm ····· 8
Fig 5. Voxel-based model Architecture: Self-Adaptive Voxelization 10
Fig 6. Self-Adaptive Voxelization Algorithm ····· 11
Fig 7. SECOND의 Self-Adaptive Voxelization ····· 12
Fig 8. Scaling Factor 선정 기준 4가지 ····· 16
Fig 9. Scaling Factor 선정 기준에 대한 Voxel 조정 진행 ····· 17
Fig 10. Self-Adaptive Voxelization in Pillar ····· 19
Fig 11. PointPillars의 Self-Adaptive Voxelization ····· 20
Fig 12. KITTI 장비 구성 및 각 센서 정보 ····· 22
Fig 13. 3D 객체 인식 시각화 - SECOND 원본(좌), SAV 적용(우) ····· 24
Fig 14. 3D 객체 인식 시각화 - PV-RCNN 원본(좌), SAV 적용(우) ···· 25
Fig 15. 3D 객체 인식 시각화 - MVX-Net 원본(좌), SAV 적용(우) ····· 26

표 목차

Table 1. 3D Object Detection 센서 특성 비교 ·····1
Table 2. 연구 목표 및 평가 방법 ·····4
Table 3. Average Precision in Bird's-Eye View(BEV) ·····27
Table 4. Average Precision in 3D View ·····28

국문 요지

본 논문은 LiDAR 기반 3D 객체 탐지의 정밀도를 향상시키기 위한 새로운 적응형 Voxel 조정 기법을 제안한다. 3D 객체 탐지에서의 LiDAR 센서는 먼 거리나 객체의 방향을 인식하는 데에 유리하나, 점 밀도가 낮은 영역이나 작은 객체에 대한 세밀한 인식이 어렵다는 한계가 있다. 이를 해결하기 위해 Voxel 내부의 점 밀도와 Voxel 중심으로부터의 상대 거리를 기반으로 Voxel 크기를 동적으로 조정하는 Self-Adaptive Voxelization(SAV) 기법을 소개한다.

SAV는 Voxel 내부의 정보를 효율적으로 수집하여 정의하고, 정규화를 진행하여 Scaling Factor를 통해 Voxel 크기가 극단적으로 변화하지 않도록 균형 있게 조정하여, Voxel 내부의 밀도 및 상대 거리에 따라 적절한 Voxel 크기를 할당해 세밀하고 효율적인 특징 추출을 시행한다.

본 논문의 아이디어를 직접 구현하고 성능을 검토해보기 위해, KITTI 데이터셋과 MMDetection3D 오픈소스 프레임워크를 통해 PointPillars, SECOND, PV-RCNN, MVX-Net, Part-A2 모델에 대해 SAV 기법을 적용하여 기존 원본의 모델과 성능을 비교해 보았다. 다음 실험을 진행한 결과, PV-RCNN과 MVX-Net은 작은 객체에 대한 인식 성능이 크게 향상되어, 세밀한 객체 탐지에 좋은 성능을 입증했다. 그러나 PointPillars와 같이 고정된 2D Grid 구조를 기반으로 연산을 진행하는 모델은 성능 저하가 발생하였고, 긍정적 성능을 보이던 PV-RCNN과 MVX-Net은 중간 크기 객체(Cyclist)에서 오히려 성능이 낮아지는 한계가 관찰되었다.

결론적으로, Self-Adaptive Voxelization 기법은 객체의 밀도 및 크기 상황에 맞게 Voxel 크기를 유연하게 조정해 작은 객체에 대한 인식 성능을 효과적으로 향상시키는 방법이다. 그러나 이에 유의할 점으로, 실험 결과에 나타난 한계를 고려해야 할 요소를 선정하였고, 이에 향후 연구는 다음과 같이 선정하였다. 중간 크기 객체에 대한 성능 개선, 고정된 Grid 기반 모델의 호환성 강화, 다양한 데이터셋의 적용 여부 및 검증을 진행하여 Self-Adaptive Voxelization 기법의 범용성을 확장할 예정이다.

제1장 서 론

1.1 연구 배경

3D 객체 검출(3D Object Detection)은 자율 주행, 로봇 공학 분야의 핵심 기술로, 지각 센서를 통해 수집한 Point Cloud 데이터를 분석해 객체의 유형, 위치, 크기, 방향 등을 예측하고, 3차원 공간에서의 Bounding Box를 생성 하는 것을 목표로 한다. 3D 객체 검출 기술은 자동차의 주행 안전 시스템인 첨단 운전 보조 시스템(ADAS) 및 자율 주행 기술, 효율적인 경로 계획, 로봇 공학에서의 물체 조작 및 행동 결정 수행 등 다양한 역할을 수행한다.

3D Object Detection에서 사용하는 대표적인 지각 센서, LiDAR와 스테레오 카메라에 대한 특징을 아래의 표, Table 1에 정리하여 나타내었다.

특징	LiDAR	Stereo Camera
세밀한 객체	제한적 (밀도에 따른 제약)	**유리함 (세부 구조 제공)**
먼 객체	**유리함**	제한적
객체 방향	**유리함**	제한적
처리 기술	**간단한 거리 및 반사율 계산**	복잡한 딥러닝 기반 시차 추론
범위	**200m 이상 안정적**	10~30m, 이후 오차 증가
비용	높음	**낮음**
밤	**안정적**	제한적
비, 눈, 안개	성능 저하	성능 저하

Table 1. 3D Object Detection 센서 특성 비교

다음과 같이 각 지각 센서의 장단점이 명확하게 구분되는 상황에서 실험을

진행하는 연구자나 회사들은 목적에 따라 알맞은 센서를 고르거나, 둘 다 사용한 센서 융합으로 단점을 보완하는 등의 선택을 진행할 것이다.

만일 3D Object Detection을 기반으로 작업을 수행하는 것이 주요 목적이라면, LiDAR 센서를 사용하여 안정적이고 넓은 범위의 객체 인식 및 간단한 처리 기술로 3차원에서의 객체를 인식하는 데 무리가 없다 생각된다. 이때, LiDAR는 세밀한 객체 인식에서의 제약이 어느 정도 문제가 되는데, 이에 대해 보완할 수 있는 Voxelization 기법을 본 논문에서 소개하고자 한다.

1.2 최신 CNN 연구 동향

최근 인공지능 기술의 발전과 함께 심층 신경망(Deep Learning)을 기반으로 Point Cloud 데이터를 처리하는 기법들이 제안되고 있다. 포인트 단위[1] 처리, 그래프 기반[2] 처리, Attention[3][7] 기법 등 다양한 기법들이 존재하나, 3D 객체 검출 분야에서 주요하게 활용되는 방법은 Voxel을 이용해 입력 Point Cloud 데이터를 공간적으로 분할하여 Feature를 추출하는 방법[4][8]이다. Voxel 방법으로 추출된 Feature는 컨볼루션 신경망(CNN, Convolution Neural Network)을 통한 연산으로 객체에 대한 학습을 진행한다. 이는 입력 데이터의 3D 공간적 특성과 구조적 정보를 체계적으로 표현할 수 있다는 장점이 있고, 복잡한 3차원 공간 내에서 중요한 특징을 학습하여 의미 있는 정보를 추출하여 객체를 인식한다.

최근 CNN 기반 심층 신경망 모델은 어떠한 방식을 통해 발전시키고, 성능이 높게 나타나는지 자세한 정보와 지표를 알아보기 위해, Object Detection 분야의 CNN 모델인 ConvNeXt[5]를 분석하였다. 일반적으로 2D Image를

입력 데이터로 사용하는 Object Detection은 본 연구에서 다루는 3D Object Detection과 분야가 다르나, 입력 이미지에 대해 모서리, 경계선, 질감과 같은 저수준(Low-level) 특성을 추출한 뒤, 객체의 윤곽이나 배경 및 전경 구분 같은 고수준(High-level) 특성으로 점진적으로 발전시켜, 컨볼루션 신경망이 데이터를 깊고 풍부하게 학습하는 공통점이 있다. 즉, 사용하는 데이터와 적용 기술이 다르더라도, CNN 기반의 특징 추출 및 데이터 해석의 흐름이 비슷해 연구에 도움이 되는 Object Detection의 최신 CNN 모델을 참고하였다.

ConvNeXt[5]는 ResNet[6]의 단순하고 효율적인 설계 구성을 기반으로 하면서도, 최신 Vision Transformer(ViT)[7] 모델의 아이디어에 영감을 받아 구조를 개선한 신경망 모델이다. 이 모델은 ViT[7]에서 활용된 훈련 기법 및 파라미터 세팅, 스테이지별 블록 비율을 같게 적용하거나, Transformer[3]의 Multi-Layer Perceptron(MLP) 블록의 Inverted Bottleneck 구조를 채택하여 중간 단계에서 채널을 4배로 확장·축소하여 계산 효율성을 극대화하면서 모델의 표현력을 유지하거나 증가하였다. 이러한 설계들을 적절히 적용해 당시 높은 성능을 보였던 ViT 모델들보다 능가하는 성과를 입증하였다.

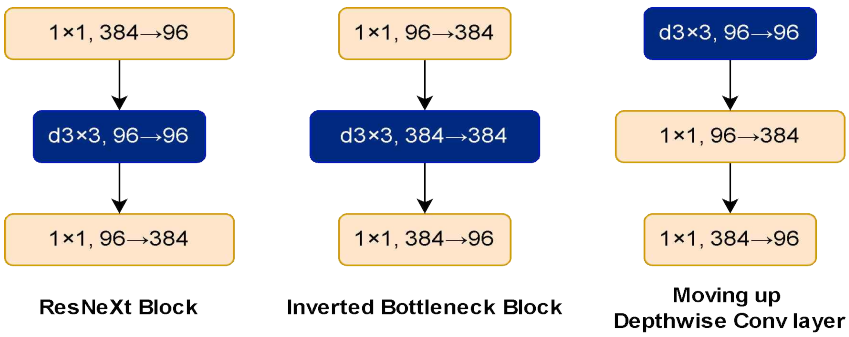

Fig 1. ConvNeXt block modification

이로써 ConvNeXt[5] 모델의 시사점은, 기존 CNN 기반 딥러닝 모델에도 적절한 아이디어를 적용하면 성능이 크게 향상될 수 있으므로, 전통적인 접근 방식에서도 정교하게 구성된 새로운 아이디어를 도입하면 성능을 크게 향상할 수 있는 구조 설계가 가능하다는 점을 입증했다. 이에 입각하여, Convolution 연산을 진행하는 Backbone 및 Neck을 적절한 구조로 변형하는 방법이 아닌, Encoder 부분에 대해 좀 더 효율적이고 세밀한 특징을 추출하는 새로운 아이디어를 구상해 연구를 진행 하였다.

1.3 연구 목표

본 연구의 목표는 다음과 같다. 첫 번째, LiDAR 센서로 작은 객체나 희소한 영역의 객체에 대해 세밀한 인식을 가능하게 하는 새로운 Voxelization 기법 아이디어를 구성하는 것이며, 두 번째는 새롭게 만들어낸 Voxelization 기법이 실제 Voxel 기반 모델에서의 성능 향상이 이뤄지는지 검증한다. 목표 수행을 위해 KITTI Dataset[15]을 사용해 나타난 성능 지표를 분석해 3D Object Detection의 새로운 가능성을 제안하며, 실질적 개선 방향을 제시한다.

연구 목표	평가 방법
• LiDAR 센서가 희소한 영역이나 작은 객체에 대한 세밀한 인식이 가능한 새로운 기법 개발	• KITTI Dataset을 통한 훈련 진행 및 3D 검출 시각화 및 분석
• 새로운 Voxelization 기법을 실제 Voxel 기반 모델에 적용하여 성능 향상 검증	• KITTI Dataset을 통한 딥러닝 모델의 AP(Average Precision) & Reference Time 평가

Table 2. 연구 목표 및 평가 방법

1.4 연구 내용

본 연구는 3D 객체 인식 분야의 Voxel 기반 딥러닝 모델이 사용하는 Voxelization 기법을 개선한 새로운 아이디어로 정교한 특징 추출을 가능하게 하는 적응형 Voxel화 조정 기법인, Self-Adaptive Voxelization을 고안하였다. 이는 Point Cloud에 대해 균일 분할한 Voxel 내부 점 밀도와 점 간 거리 정보를 통해 Voxel 크기를 동적으로 조정함으로써 지역적 특징을 더 세밀하게 포착하는 기법으로, Point Cloud의 밀도가 낮은 공간이거나 객체 크기가 작아 인식이 원활하게 이뤄지지 않는 경우, 작고 세밀한 인식이 필요한 상황에 맞게 적응·조정하여 유연하고 정교한 특징 추출로 향상된 성능을 보인다. 본 논문은 Self-Adaptive Voxelization 기법으로 기존 Voxel 기반의 CNN 모델의 성능을 효과적으로 상향시킬 수 있음을 실험적으로 입증한다.

제 2장 관련 연구

3D Object Detection에서 CNN을 효과적으로 활용하려면 Point Cloud 데이터로부터 Feature를 추출하는 과정이 필요하다. 이에 따라, Feature 추출 과정과 밀접하게 연관된 Voxel 및 Pillar의 개념과 이를 대표하는 딥러닝 모델을 함께 정리하며, 본 연구에 목적에 맞게 수정 및 확장한 주요 참고 아이디어인 Dynamic Voxelization 기법에 대해 정리하고자 한다.

2.1 Voxel-based model

Voxel 기반 모델에서의 Feature 추출을 진행하는 Encoder는 단계는 다음과 같은 순서로 진행된다. Voxelization은 Point Cloud 데이터를 일정한 크기의 Grid로 균등하게 분할하고, 3차원 공간에서의 Pixel(Voxel)을 만드는 과정이다. Voxelization 과정 이후, 생성된 각 Voxel 내부의 점들에 대해 일정한 점의 수를 가지도록 Sampling 과정을 진행한다. 이에 대한 Encoding 작업을 수행하여 Voxel 내부 점들의 정보에 대한 Voxel Feature를 추출하게 된다. Point Cloud의 지역적 관계가 잘 반영된 Voxel Feature들은 이후 과정인 CNN 학습에 사용되며, 메모리에 효율적이고 세밀한 데이터 저장 및 해석이 가능해진다.

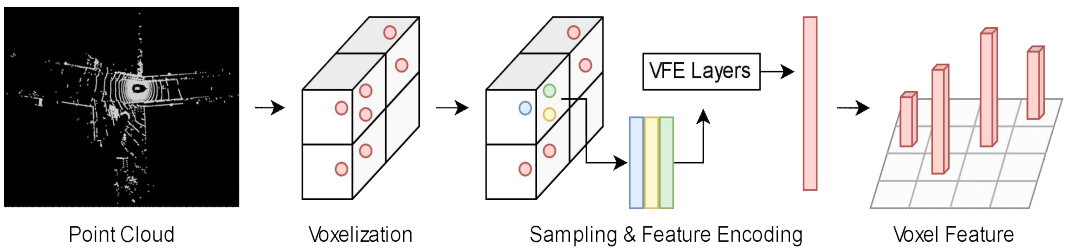

Fig 2. Voxel-based model Encoder Architecture

VoxelNet[4]은 Point Cloud 데이터에 Voxelization 개념을 최초로 도입하여 3D Convolution 연산을 수행한 모델이다. 이후 Sparse한 Point Cloud의 특성을 고려하여 더 빠르고 효율적인 계산 방법을 제공하는 SECOND[8]. Point 단위 처리와 Voxelization 기법을 결합한 PV-RCNN[9] 등 다양한 발전된 모델들이 등장하였다.

2.2 Pillar-based model

Voxel 기반 모델은 3D Convolution 연산을 사용하여 많은 Parameter를 사용하므로 계산이 많고 속도가 느려 실시간 응용에는 다소 한계가 있다. 이러한 점을 극복하기 위해 Pillar 기반의 방법이 개발되었다.

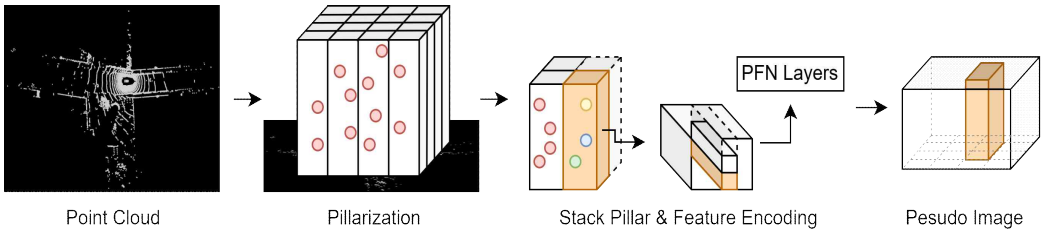

Fig 3. Pillar-based model Encoder Architecture

대표적인 Pillar 기반 모델인 PointPillars[10]는 Point Cloud 데이터를 2D Grid로 분할하고, XY 평면에 대해 투영을 진행한다. 이때 Z축에 제한을 두지 않게 하여 일종의 사각기둥(Pillar)의 공간을 형성하여 Voxel 기반 방법보다 더 많은 점을 포함하게 된다. 기둥 내부의 점에 대한 Sampling 및 Encoding 과정은 Voxel-based model Encoder에서의 시행 과정과 유사하고, 최종적으로 Pesudo Image(2D Pillar Feature)를 생성하여 2D Convolution 연산을 가능하게 한다.

Pillar 기반 모델은 Voxel 기반 모델보다 적은 Parameter로 계산을 진행하여 학습하므로, 가볍고 빠른 연산 속도로 실시간 응용에 적합한 성능을 제공한다. 2D Grid로 투영하는 방식이 학습 속도는 빠르지만, 상대적으로 낮은 성능을 보인다는 한계가 존재한다. 이를 보완하기 위해 PillarNet[11], FastPillars[12]와 같은 Pillar 기반 최신 모델들은 개선된 Pillar Encoder와 효율적인 Backbone 설계를 구현하여 객체 인식 성능을 향상하였다.

2.3 Dynamic Voxelization

기존 Voxel 기반 모델은 고정된 크기의 Grid로 분할하여 Point Cloud를 나누어 특징을 추출하는 방식이나, Point Cloud는 점들이 희소하거나 밀집된 영역이 혼합된 불균일한 분포를 나타내어 객체의 세밀한 정보를 반영하는 데 한계가 나타나게 되었다. 이를 해결하기 위해 Dynamic Voxelization 개념이 나타나게 되었다.

Dynamic Voxelization은 Point Cloud에서의 점이 밀집된 정도에 따라 Voxel의 크기 · 위치를 유동적으로 조정하고, 효율적인 특징 추출을 진행한다. 이는 점이 희소한 영역이나 먼 거리에서의 객체 인식에 효과적이다.

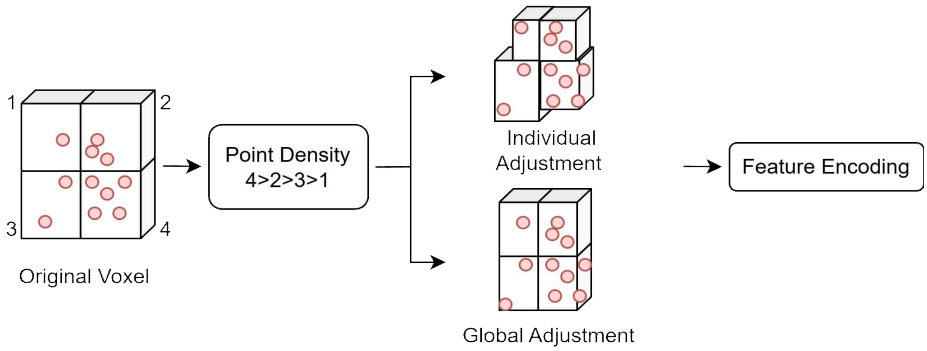

Fig 4. Dynamic Voxelization Algorithm

Dynamic Voxelization 기법은 크게 두 가지 Voxel 크기 조정 방법을 사용한다. 첫 번째는 Voxel 크기를 각각 개별적으로 세밀하게 동적 조정하는 방법으로, 각 Voxel 마다 지역적 특징을 다르게 반영하여 객체 인식 정밀도를 높이는 데 중점을 둔다. Multi-View Fusion(MVF)[13]는 Voxel의 밀도에 따라 각 Voxel 크기를 동적 조절하여 밀도가 높은 영역은 작은 Voxel, 낮은 영역은 큰 Voxel을 사용하여 세밀한 객체 인식을 진행한다.

두 번째는 전체 Voxel 크기를 동적으로 조정하는 방식으로, Voxel 간의 크기 차이를 최소화하여 연산 효율을 극대화하는 데 초점을 맞춘다. 전체적인 객체 조정을 통해 학습을 안정적으로 진행하고 객체의 일관된 특징 추출이 가능해진다. DV-ConvNet[14]은 점 밀도에 따라 Voxel 크기를 동적으로 조정하되, Voxel 간 차이가 크게 발생하지 않도록 연산 효율성을 유지하면서 정보 손실을 최소화하여 안정적인 학습을 진행한다.

이처럼 Dynamic Voxelization은 데이터 특성에 따라 세밀한 정보 통합과 효율적인 객체 인식 중 어느 부분에 더 중점을 둘지 결정하여 적용할 수 있는 유연한 기법이다.

제 3장 기법 제안

본 연구에서는 Voxel 및 Pillar 방식을 사용하는 CNN 모델에서 멀리 있거나 작은 객체에 대한 인식 성능을 향상하는 새로운 방식의 동적 Voxelization 기법을 고안하였다. Dynamic Voxelization 기법과 유사하게, Voxel 내부의 점 밀도와 Voxel의 중심으로부터의 상대적 위치 정보를 중심으로 전체적인 Voxel 크기를 동적 조정하여 세밀한 객체 인식을 진행하는 Self-Adaptive Voxelization(SAV)를 소개한다.

3.1 Self-Adaptive Voxelization

Self-Adaptive Voxelization(SAV)은 3D Object Detection에서 Voxel의 정밀한 특징 추출을 위한 적응형 기법으로, Voxel Encoder의 Voxelization 과정을 개조하여 Voxel 내 밀도와 상대 거리를 통해 Voxel 내부 상황을 검토하고 크기를 동적 조정하는 기법이다.

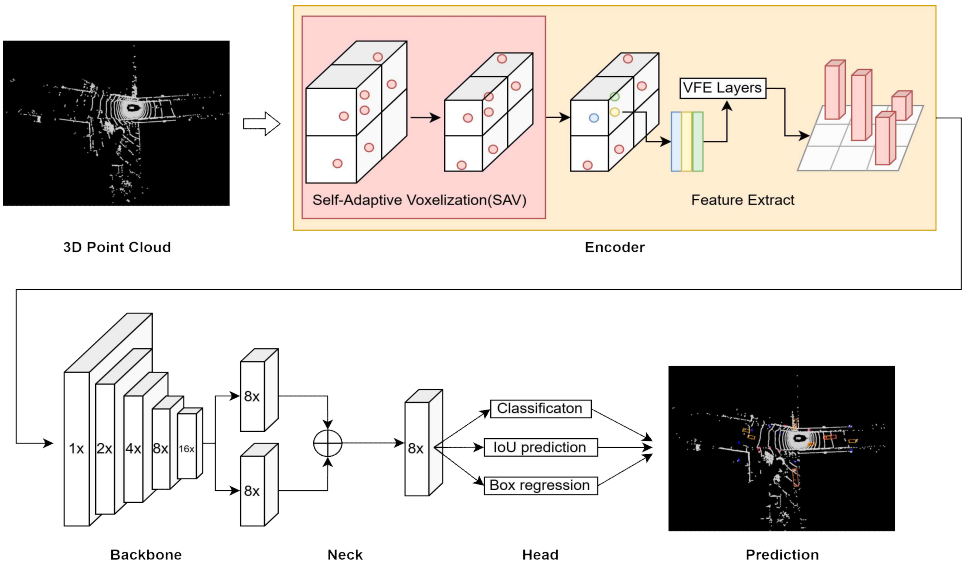

Fig 5. Voxel-based model Architecture: Self-Adaptive Voxelization

다음 Fig 5.는 Self-Adaptive Voxelization을 Voxel 기반 모델에 적용하였을 때 전체적인 모델 구성으로, 적용한 Encoder 내 Voxelization 과정을 Self-Adaptive Voxelization 기법으로 바꾸어 적용하였고, 이를 통해 변형된 Voxel 크기를 기반으로 Feature 추출 및 학습을 진행한다.

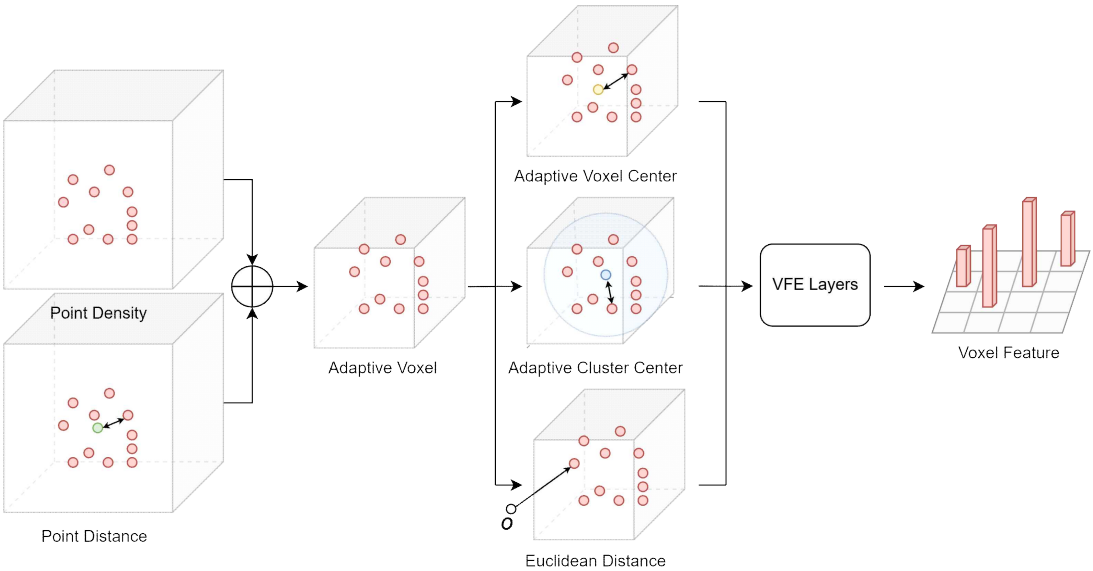

Fig 6. Self-Adaptive Voxelization Algorithm

Fig 6.은 Self-Adaptive Voxelization이 어떠한 방식으로 일어나는지 자세한 알고리즘을 나타낸다. Voxel 내부의 밀도 및 상대 거리 정보들을 수집하고, 두 정보를 기반으로 전체적인 Voxel 크기를 얼마나 조정해야 하는지 자체적인 평가 및 조정을 진행해 기존에 처음 설정한 Voxel 크기에서 Adaptive Voxel로 바꾸어 크기를 수정한다. Voxel 크기 조정은 점의 수가 많아 밀집된 영역이나 점들의 평균 위치와 Voxel 중심 간 상대 거리가 가까운 경우, Voxel을 작게 조정하여 정보를 세밀하게 유지하고, 반대로 점의 수가 적어 희박하거나 상대 거리가 먼 경우는 큰 Voxel을 할당하여 연산 효율

성을 높여 입력된 Point Cloud 데이터에 알맞게 조정한다. 조정된 Voxel 크기는 Voxel 중심, Cluster 중심, Euclidean 거리에 대한 다양한 공간적 특징을 추출해 VFE Layer를 거쳐 최종 Voxel Feature를 생성하는 방식이다.

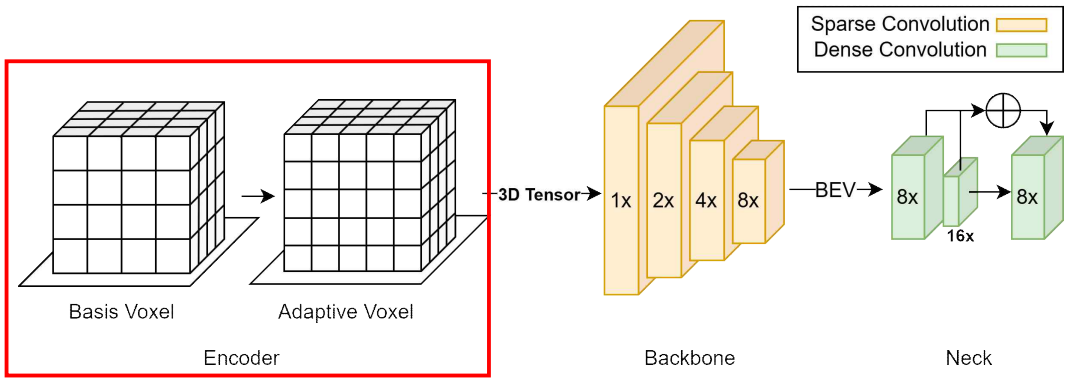

Fig 7. SECOND의 Self-Adaptive Voxelization

실제 Voxel 기반 딥러닝 모델인 SECOND[8]에 SAV를 적용한다면, Fig 7.과 같이 Voxel 내부의 Point Cloud 데이터의 밀도와 상대 거리에 따라 Voxel 내 밀도가 높으면 기존 Voxel 크기보다 전체적으로 작게 조정되어 Point Cloud에 대한 Voxel 개체가 많아지고, 이에 대한 Feature 추출 및 3D Convolution 연산을 진행하여 객체에 대한 세밀한 인식을 가능하게 한다.

3.2 Self-Adaptive Voxelization 공식 적용

SAV는 Voxel의 크기를 동적으로 조절해 효율적이고 세밀한 인식이 가능하게 하는 점을 중시한다. 이를 위해 SAV의 두 가지 기준인 점 밀도와 점의 상대 거리를 활용하되, 기존과 다른 접근 방식을 채택하였다.

$$D_{point} = N_{points} \tag{1}$$

$$d_{voxel} = \left(\frac{1}{N_{points}} \sum_{i=1}^{N_{points}} p_i\right) - p_{center} \tag{2}$$

Equation 1. Voxel 밀도 및 상대 거리

D_{point}: 점 밀도, d_{voxel}: Voxel 중심과 점 평균 간의 상대 거리
N_{points}: Voxel 내 점의 개수
p_i: Voxel 내 각 점의 좌표, p_{center}: Voxel 중심 좌표

다음은 SAV에서 사용한 밀도 및 상대 거리 공식이다. 수식 (1)은 점의 밀도, 수식 (2)는 Voxel 중심과 각 점들의 평균에 대한 상대 거리를 의미한다. SAV는 기존의 Voxel 크기에 대해 고정된 것이 아닌, 동적으로 조정되므로 밀도를 나타낼 때 Voxel 부피를 나누지 않고 내부 점 개수만을 지표로 활용하였다. 또한, 점 간 상대 거리 정보는 각 점의 좌표에 대해 계산하면 연산량이 매우 많아지므로, Voxel 내부 점들의 위치 정보 값을 평균으로 나타냈고, 이에 대해 Voxel 중심과의 거리 차이로 계산하였다. 이는 Voxel 크기가 변하더라도 일관된 정보로 안정적인 계산을 가능하게 하며, 점 간 관계보다 전역적 분포를 조사해 Voxel 크기를 적응적으로 바꾸는 것이 목적이므로, 불필요한 세부 정보를 반영하지 않았다. 이를 통해, 점이 공간적으로 얼마나 집중되어 있는지 파악할 수 있다.

$$D_{norm} = \frac{D_{point}}{D_{\max}} = \frac{N_{points}}{N_{\max}} \tag{3}$$

$$d_{norm} = \frac{d_{voxel}}{d_{\max}} = \frac{p_{mean} - p_{center}}{\sqrt{v_x^2 + v_y^2 + v_z^2}} \tag{4}$$

Equation 2. 밀도 및 상대 거리 정규화

D_{norm}: 정규화 밀도, d_{norm}: 정규화 거리

$N_{\max}$: Voxel 내 최대로 있을 수 있는 점 개수

$d_{\max}$: Voxel 최대 거리(대각선)

다음 공식 Equation 2.는 밀도 및 상대 거리에 대한 정규화 과정을 나타낸다. 후술할 Scaling factor에 밀도 및 상대 거리를 안정적인 연산을 위해 값을 균형적으로 조정하는 정규화 과정을 진행하였다. 정규화는 최대 Voxel 밀도와 최대 Voxel 거리를 기준으로 수행되며, 이를 통한 모델 학습 시 두 값의 상대적인 크기만을 유지하면서 과도한 영향을 방지한다.

$$S = \log(1 + \alpha\sqrt{d_{norm} + \epsilon} + (1 - \alpha)\frac{1}{\sqrt{D_{norm} + \epsilon}}) \tag{5}$$

$$V_{adapt} = V_{voxel} \times S \tag{6}$$

Equation 3. Scaling Factor 및 조정된 Voxel 크기

S: Scaling factor ($0.5 \le S \le 1.5$), V_{adapt}: 동적 조정된 Voxel size

α: 밀도 및 거리의 가중치 계수

ϵ: 연산 보정 계수(아주 작은 값, 예:1×10^{-6})

Scaling factor는 정규화 된 밀도와 상대 거리 정보를 기반으로, Voxel 크

기의 동적 조정을 시행하기 위한 핵심 공식이다. 다음 공식은 정규화 된 밀도 및 상대 거리에 대해 비선형 함수를 사용하여 값이 극단적으로 치우치지 않고 점진적인 변화를 유도하여 균형 잡힌 스케일링이 가능하도록 구성하였다. 또한, Voxel 크기의 확장・축소가 너무 과하게 변하지 않도록 상한 및 하한 범위($0.5 \leq S \leq 1.5$)를 설정하였다. 본 연구에서는 밀도 및 거리의 가중치를 동등하게 설정하였으나 필요시 데이터의 특성에 따라 가중치를 조정할 수 있다.

최종적으로, 동적으로 조정된 Voxel 크기는 계산된 Scaling factor를 기존 Voxel 크기에 곱하여 나타낸다. 이를 통해 점 밀집도가 높은 영역에서는 작은 Voxel을, 점의 분포가 희소한 영역에서는 큰 Voxel을 할당하여 학습의 효율성을 높이고 세밀한 특징 추출을 가능하게 한다.

3.3 Scaling Factor 조정 기준

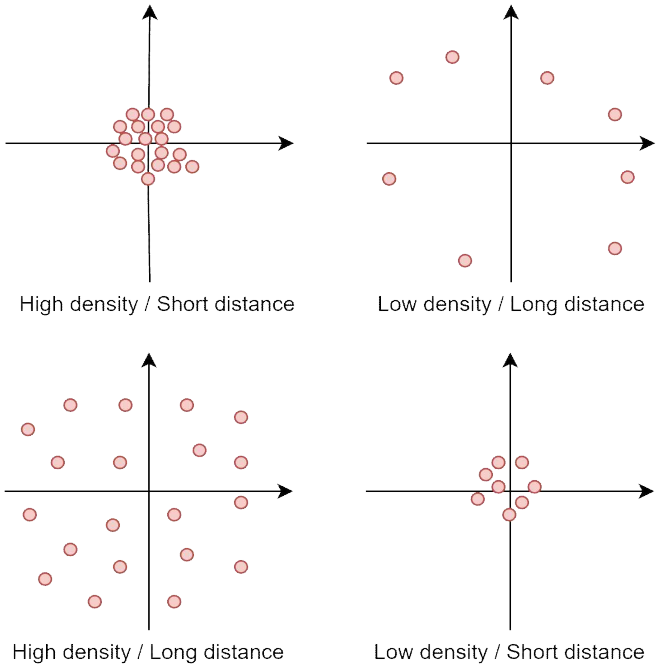

Fig 8. Scaling Factor 선정 기준 4가지

Self-Adaptive Voxelization 기법에서 Voxel 크기를 조정하는 핵심 요소, Scaling factor는 점 밀도 및 상대 거리의 높고 낮은 4가지 경우를 기준으로 설정하였다. 그림 Fig 8. 에 나타난 경우와 같이, 높은 밀도 및 짧은 거리, 낮은 밀도 및 먼 거리, 높은 밀도 및 먼 거리, 낮은 밀도 및 짧은 거리에 대해 초기에 설정했던 Voxel 크기를 어떤 방법으로 조정해야 할지 기준을 설정하여 연구를 진행하였다. Voxel 조정은 밀도 및 거리 요소 둘 다 고려하여 Voxel 조정을 진행하되, 점 밀도를 중심으로 진행하고, 점 간 상대 거리는 이를 보완하는 요소로 작동 되도록 설정하였다.

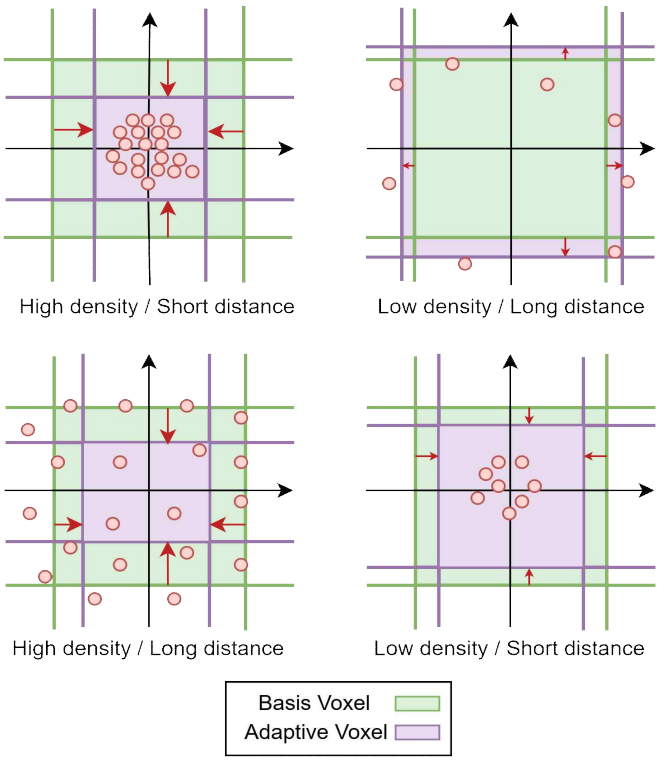

Fig 9. Scaling Factor 선정 기준에 대한 Voxel 조정 진행

설정한 Scaling Factor에 따른 Voxel 조정을 시행했을 때, 다음 Fig 9.의 결과대로 크기 조정일 일어났다. 각 기준의 상황 및 결과를 기반으로 분석하자면 다음과 같이 나타난다.

1) High density & Short distance

점이 밀집되어 있고, 점 간 거리가 짧은 경우는 세부적이고 정밀한 연산이 필요하다. 이런 경우, Scaling factor를 작게 설정하여 작은 Voxel을 생성하고, 세밀한 정보를 효율적으로 학습할 수 있도록 한다.

2) Low density & Long distance

Voxel 내부의 점의 밀도가 낮고, 점 간 거리가 먼 경우는 점 개수가 적어 세부 정보가 부족할 가능성이 크다. 따라서 Scaling factor를 크게 설정하여 Voxel 크기를 키우고, 효율성을 높이는 방향으로 조정한다.

3) High density & Long distance

점의 밀도가 높아 많은 정보를 포함하나, 점 간 거리가 멀어 객체의 분포가 넓은 경우이다. 다음 상황은 높은 밀도를 고려하여 세밀한 정보를 학습하기 위해 Scaling factor를 작게 조정하여 Voxel 크기를 줄인다. 이는 거리가 멀다는 점을 고려하여 1)의 경우보다 더 작은 값으로 설정되지 않도록 적절히 Voxel 조정을 진행한다.

4) Low density & Short distance

밀도가 낮고 점 간 거리가 짧은 상황에는 인식되는 점의 개수가 적어 단순히 Voxel 크기를 줄이는 것은 유리하지 않을 수 있다. 이러한 경우는 Scaling factor를 작게 조정하되 큰 변화를 주지 않아야 하며, 안정적인 크기로 원활한 객체 인식을 진행한다.

결론적으로, Scaling factor 조정의 핵심 원리는 Voxel 내의 점 밀도를 중심으로 점들에 대해 세밀한 인식을 수행하며, 점 간 상대 거리 정보를 함께 고려해 조정을 진행한다. 이는 단순히 점이 많다고 무조건 작은 Voxel을 만드는 게 아닌, 점 간 상대 거리 정보도 반영하여 Point Cloud 데이터의 다양한 특성에 유연히 적응하도록 한다. 즉, 밀도가 높으면 점 간 거리가 멀어도 객체를 이루는 점이 많이 분포되어 점 간 거리를 가깝게 간주해 Voxel 크기를 줄이는 것이고, 밀도가 낮은 경우 점 간 거리가 좁아도 객체를 포착한 점

자체가 적어 Voxel 크기를 줄이더라도 과하게 줄이지 않도록 한다.

3.4 Pillar에서의 Self-Adaptive Voxelization

Pillar 기반 모델에 SAV 기법을 적용하는 방식은 Voxel 기반에서 다루는 접근 방식과 유사하지만, Pillar의 특성에 맞게 일부 요소를 추가로 고려하여 설정하였다.

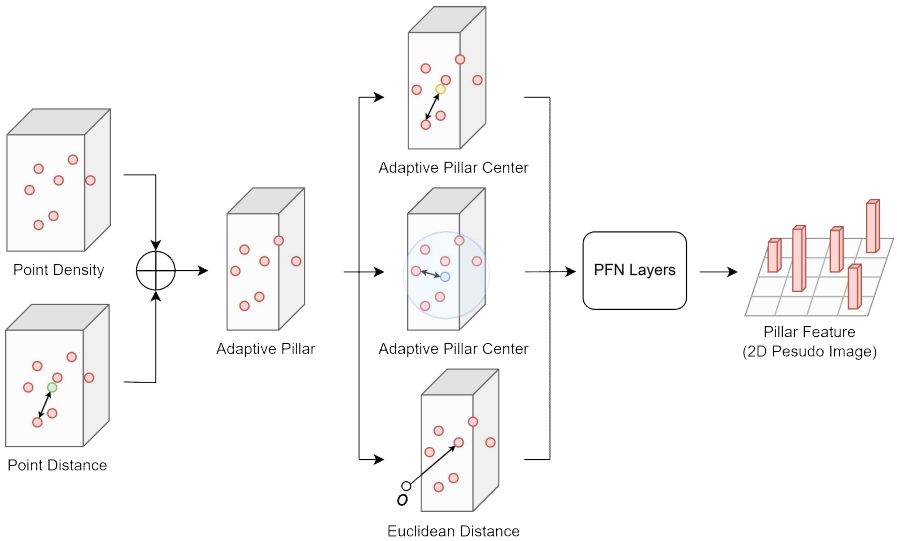

Fig 10. Self-Adaptive Voxelization in Pillar

$$P_{adapt} = (v_x \times v_y) \times S \tag{7}$$

Equation 4. Pillar에서의 조정된 Voxel 크기

P_{adapt}: 조정된 Pillar 크기 (XY 평면만 고려)

Pillar는 Point Cloud에 대한 분할영역을 XY평면에 대해 진행하며 Z축에

제한을 두지 않는 특성이 있어, 이에 맞게끔 Z축의 변형 없이 X,Y축에 대해서만 크기를 동적으로 조절하는 방식을 사용해 Pillar를 조정하였다.

이때, 밀도, 상대 거리, 정규화, Scaling factor를 산출하는 공식은 Voxel 기반의 SAV 기법과 동일하며, XY 평면만의 크기 조정을 시행하여 조정된 Pillar 크기를 기반으로 Feature를 추출한다. 이는 기존 Pillar 기반 모델의 특징을 유지하면서도 Point Cloud 데이터의 지역적 특성을 반영하여 더욱 정교한 특징 추출을 지원한다.

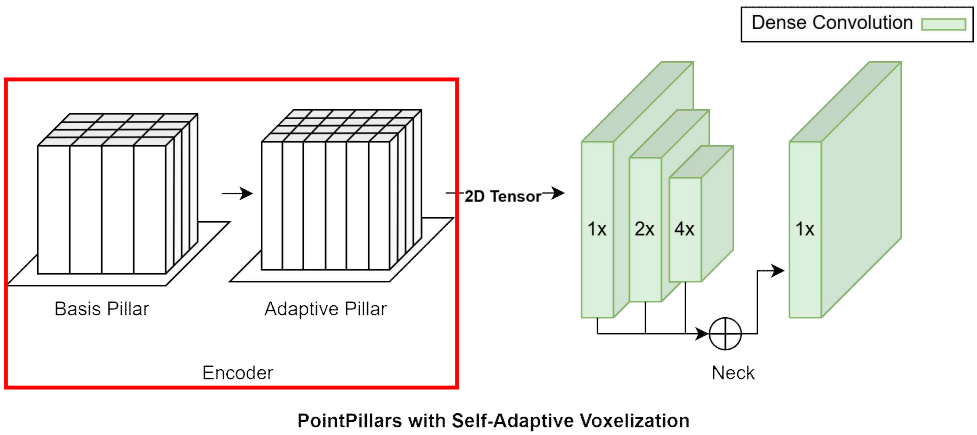

Fig 11. PointPillars의 Self-Adaptive Voxelization

실제 Pillar 기반 딥러닝 모델인 PointPillars[10]에 SAV를 적용하면, Pillar 내부의 Point Cloud 데이터의 밀도와 상대 거리에 따라 Pillar 내 밀도가 높으면 기존 Pillar보다 Z축의 크기 변화 없이 XY 평면이 더 작게 조정되어 전체적인 Pillar 개체가 많아지고, 이에 대한 Feature 추출 및 2D Convolution 연산을 진행하여 객체에 대한 세밀한 인식을 진행한다.

제 4장 실험 구성 및 진행

4.1 실험 환경

본 연구는 3D Object Detection Toolbox 오픈소스, OpenMMLab의 MMDetection3D[22]를 기반으로, KITTI Dataset[15]을 사용해 Voxel 및 Pillar 기반의 널리 잘 알려진 CNN 모델들을 대상으로 실험을 진행 하였다.

4.1.1 KITTI Dataset

KITTI Dataset[15]은 독일의 Karlsruhe Institute of Technology와 Toyota Technological Institute at Chicago의 협력으로 독일 Karlsruhe 주변의 실제 지역 환경에서 자율주행 차량으로 수집된 대규모 센서 데이터 셋으로, 고해상도 RGB, Gray Scale 스테레오 카메라, 3D LiDAR 스캐너 등 다양한 센서를 사용해 자율주행 및 컴퓨터 비전 연구에서 널리 사용되어 딥러닝 모델의 평가 지표 및 알고리즘의 Benchmark 점수를 비교할 수 있다.

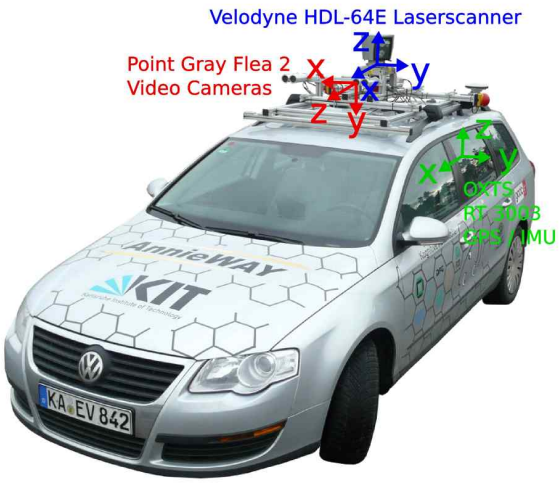

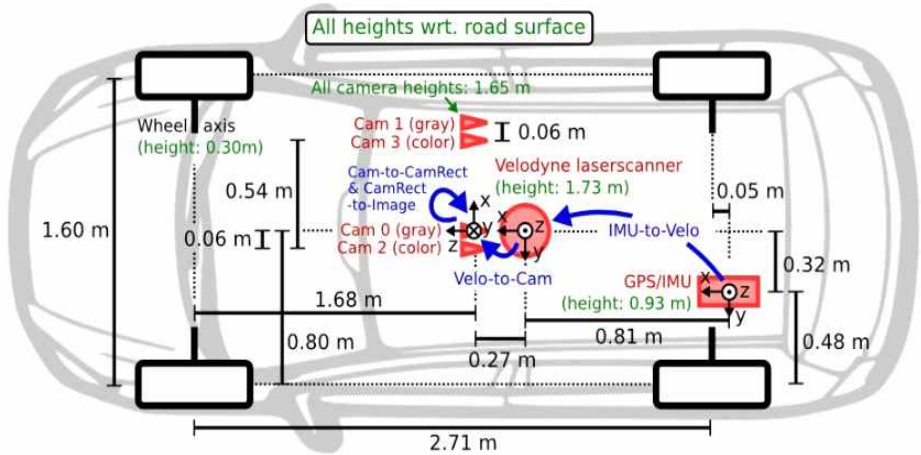

- 1 Inertial Navigation System (GPS/IMU): OXTS RT 3003
- 1 Laserscanner: Velodyne HDL-64E
- 2 Grayscale cameras, 1.4 Megapixels: Point Grey Flea 2(FL2-14S3M-C)
- 2 Color cameras, 1.4 Megapixels: Point Grey Flea 2(FL2-14S3C-C)
- 4 Varifocal lenses, 4-8 mm: Edmund Optics NT59-917

Fig 12. KITTI 장비 구성 및 각 센서 정보

본 연구에서는 LiDAR 센서로 촬영한 Point Cloud 데이터를 포함한 KITTI Object Detection Benchmark Dataset을 활용하였으며, 모델이 인식해야 할 목표 객체 Class는 Car, Pedestrian, Cyclist 3가지이다. 모델의 성능은 각 객체를 얼마나 정확하게 감지하고 분류했는지를 기준으로 평가하였다.

4.1.2 MMDetection3D

MMDetection3D[22]는 OpenMMLab에서 개발한 3D Object Detection 작업을 진행하는데 도움을 주는 오픈소스 프레임워크로, 2D 객체 검출 프레임워크인 MMDetection[16]의 확장 버전으로, LiDAR 데이터 및 Multimodal

데이터(LiDAR + RGB Image)를 사용해 3D 객체에 대한 검출, 추적, 분할 등의 작업을 지원한다. MMDetection3D[22]는 KITTI[15], nuScenes[19], Waymo[20]등 다양한 3D 객체 검출을 위한 데이터셋을 지원하고, 통합된 포맷으로 효율적인 실험을 가능하게 한다. 또한, PyTorch[21] 기반으로 설계되어 사용자에 맞는 최적화가 가능하여 효율적인 모델 학습을 위한 조율 및 새로운 모델, 손실 함수 등을 쉽게 추가할 수 있다.

4.2 실험 설정

실험에서는 KITTI Dataset[15]의 총 3712개의 Training sample과 3769개의 Test Sample로 데이터셋을 분할하였고, 20회의 Training을 통해 모델을 학습하였다. Voxel 기반 모델의 기본 Voxel size 크기는 [0.05, 0.05, 0.1]로 설정하였고, Pillar 기반 모델의 경우는 [0.16, 0.16, 4]로 설정하였다. 이 외에도 모든 실험은 동일 조건에서 MMDetection3D[22]에서 제공하는 기본 설정된 Config 파일 및 모델을 기반으로 Voxel Encoder 부분의 코드를 변형하고 비교하였다. 비교를 위한 Voxel 기반 딥러닝 모델은 주요 특징이 각기 다른 5가지로 선정하였는데, PointPillars[10], SECOND[8], PV-RCNN[9], MVX-Net[17], Part-A2[18]에 대해 원본의 경우와 SAV 기법을 적용한 경우로 비교하였다. 본 실험은 동일한 데이터 설정 옵션을 사용하여 데이터 관련 편향을 배제하여 모델의 성능 변화를 측정하였다.

4.3 실험 결과

실험에 사용한 환경 및 설정에 따른 3D 객체 인식 결과를 시각화하여 자동차, 보행자, 자전거 클래스가 어떻게 인식되는 지 관찰하였고, 평균 예측 값(AP), 특정 시점 기준의 추론 시간(Reference Time)을 표로 나타내어 원본

모델과 SAV 기법을 적용한 모델에 대한 결과를 비교하여 분석하였다.

4.3.1 KITTI Dataset – 3D Object Detection Visualization

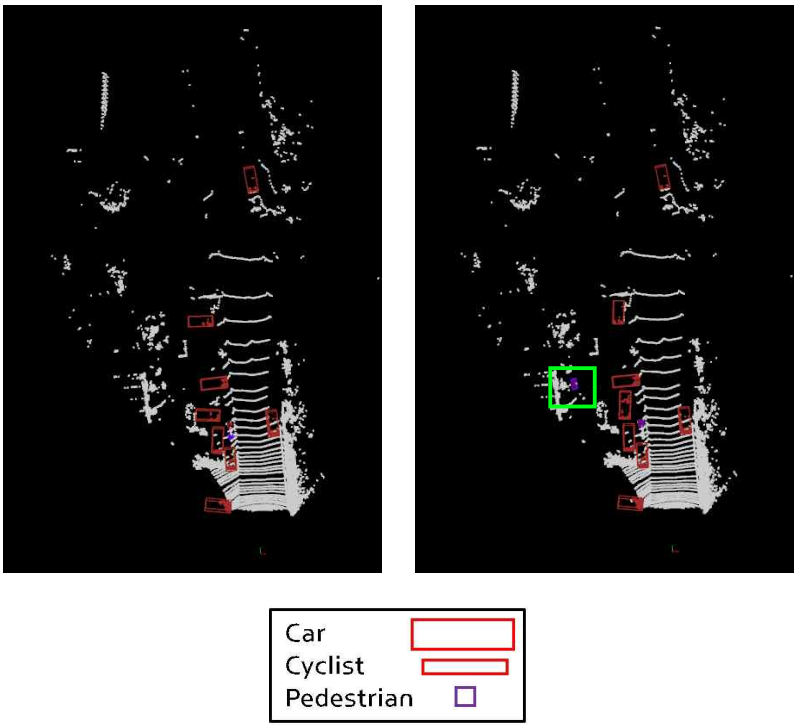

Fig 13. 3D 객체 인식 시각화 – SECOND 원본(좌), SAV 적용(우)

다음은 SECOND[8]에 대한 3D Point Cloud 객체 인식의 결과로, 모델의 원본에서의 상황과, 모델에 대해 SAV 기법을 적용한 경우 각각에 대한 시각화 상황이다. 그림을 보면, 원본에 비해 SAV 기법을 적용해도 객체 인식 차이가 크게 없으나, SAV 기법 시각화 그림의 초록색 박스와 같이 보행자에 대한 점이 한 개 정도 더 잡혀 미미하게 성능이 더 낫게 나타난다는 점을 보인다.

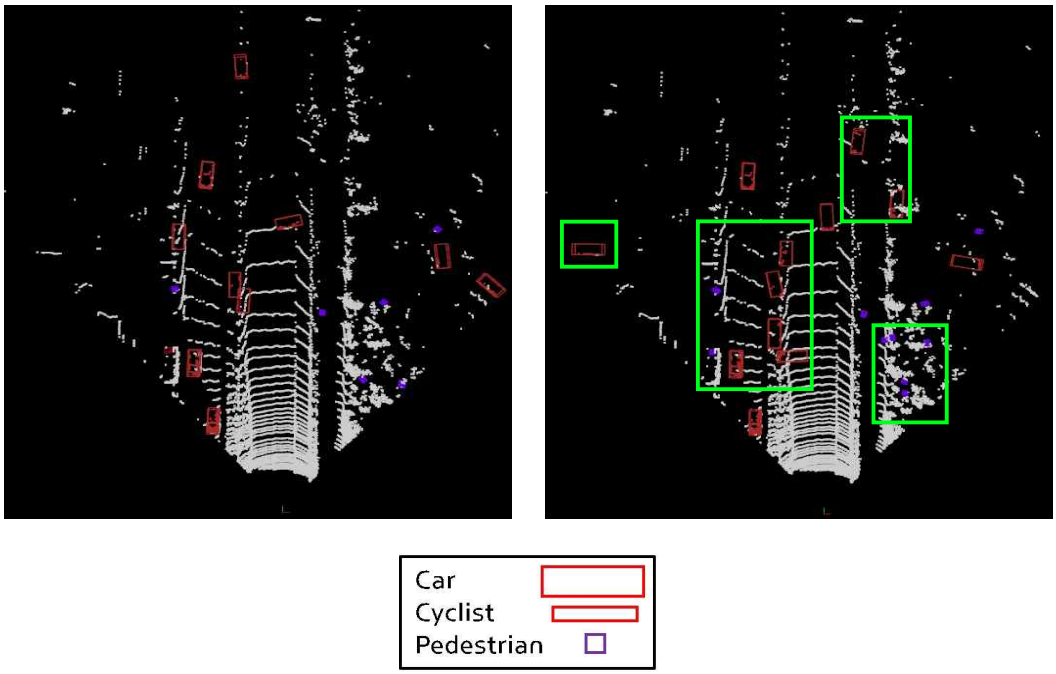

Fig 14. 3D 객체 인식 시각화 - PV-RCNN 원본(좌), SAV 적용(우)

이번엔 PV-RCNN[9]에 대한 3D Point Cloud 객체 인식 이미지이다. 원본에 비해 SAV 기법을 적용한 경우가 전반적으로 자동차 및 보행자에 대해 많은 수를 인식하는 결과를 나타낸다. 이는 실제로 SAV 기법이 작은 객체인 보행자에 대한 세밀한 인식이 이루어져 큰 성능 향상을 보이며, 큰 객체인 자동차에 대해서도 어느 정도 성능이 보장되고 있음을 나타내었다.

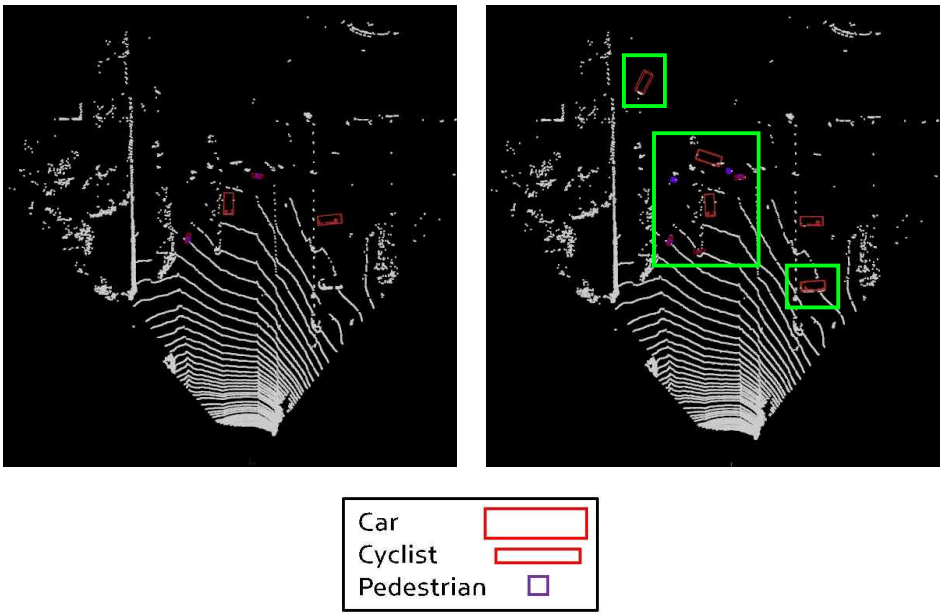

Fig 15. 3D 객체 인식 시각화 - MVX-Net 원본(좌), SAV 적용(우)

마지막으로 MVX-Net[17]에 대한 3D Point Cloud 객체 인식을 시각화한 결과로, 기법을 적용하지 않은 원본에 비해 SAV 기법을 적용한 경우가 전체적으로 자동차, 보행자, 자전거에 대해 많은 수를 인식하여 성능이 향상되고 있음을 보인다.

4.3.2 KITTI Dataset – Average Precision Result

Average Precision(AP)는 모델이 예측한 값을 Ground Truth와 비교하여 모델이 얼마나 올바르고 정확하게 물체를 감지하고 분류했는지 나타내는 핵심 지표이다. 객체 인식에 대한 예측 난이도를 Easy, Moderate, Hard로 구분하여 결과 값으로 나타내었고, 난이도의 설정은 객체의 크기, 시야각, 가려짐 정도 등 KITTI Dataset[15]의 설정에 따라 다르게 설정되었다. 추론 시간(Time)은 한 프레임의 LiDAR를 처리하고 결과를 생성하는데 걸린 시간이며, 이는 실시간 응답성을 평가하는 데 중요한 정보이다. 본 실험은 5가지의 딥러닝 모델에 SAV 기법을 적용한 유무에 따른 성능 결과를 AP 및 추론 시간의 지표로 나타내었다.

Method		Time (s)	Car (%)			Pedestrian (%)			Cyclist (%)		
			Easy	Mod.	Hard	Easy	Mod.	Hard	Easy	Mod.	Hard
원본	PointPillars	0.0371	87.90	80.52	76.61	36.70	33.29	32.14	67.52	47.91	45.35
	SECOND	0.0593	89.83	86.97	85.07	65.22	60.96	56.53	81.75	70.00	66.63
	PV-RCNN	0.1749	89.74	85.62	83.65	55.26	47.01	45.01	80.39	67.29	63.19
	MVX-Net	0.1217	89.49	85.61	79.14	55.67	52.70	48.08	64.23	45.45	42.50
	Part-A2	0.1099	90.27	87.79	87.24	67.76	61.64	57.06	86.32	72.68	69.65
SAV	PointPillars	0.0381	77.65	67.68	62.92	12.55	11.92	11.45	24.11	16.90	15.64
	SECOND	0.0617	89.70	85.37	84.41	64.71	59.24	53.40	84.39	67.57	64.65
	PV-RCNN	0.1784	89.51	85.86	82.68	60.51	53.37	49.16	77.96	64.95	62.29
	MVX-Net	0.1218	89.46	85.37	78.74	60.55	55.59	50.38	61.20	41.06	38.53
	Part-A2	0.1124	90.29	87.76	86.86	63.76	57.92	53.68	86.67	72.31	68.01

Table 3. Average Precision in Bird's-Eye View(BEV)

다음 Table 3.는 조감도(Bird's Eye View)에서의 3D Object Detection AP 결과를 나타낸 표로, PointPillars[10]는 SAV를 적용한 결과, 원본에 비해 전체 Class에 대해 높은 성능 저하를 보였으며, SECOND[8]는 전체적인

소폭 하향이 일어났다. PV-RCNN[9] 및 MVX-Net[17]에서는 Pedestrian에서의 성능이 크게 향상된 반면, Cyclist에서는 하락, Car에서는 비슷한 결과를 보인다. Part-A2[18]는 Pedestrian에서 성능이 하락하며, Cyclist 및 Car의 결과 값의 변화는 거의 없었다.

Method		Time (s)	Car (%)			Pedestrian (%)			Cyclist (%)		
			Easy	Mod.	Hard	Easy	Mod.	Hard	Easy	Mod.	Hard
원본	PointPillars	0.0371	55.62	48.19	43.73	26.77	24.47	23.17	57.62	40.86	38.78
	SECOND	0.0593	85.91	75.53	68.47	60.61	55.61	51.11	80.00	66.46	61.21
	PV-RCNN	0.1749	87.71	77.22	76.15	51.18	44.06	39.83	78.68	65.25	60.48
	MVX-Net	0.1217	84.16	73.49	67.59	43.67	41.62	37.96	59.07	40.50	38.86
	Part-A2	0.1099	89.13	78.72	78.13	65.46	58.58	53.38	84.48	69.87	66.51
SAV	PointPillars	0.0381	29.64	26.82	25.46	11.28	10.51	10.56	14.93	10.67	9.60
	SECOND	0.0617	86.23	75.16	68.43	60.27	53.25	48.26	78.85	62.90	59.09
	PV-RCNN	0.1784	86.38	75.99	73.33	56.86	49.59	44.63	75.42	61.05	57.17
	MVX-Net	0.1218	83.91	73.26	67.13	51.65	47.42	44.53	58.01	38.51	36.81
	Part-A2	0.1124	89.59	79.00	78.34	61.31	54.68	49.67	86.01	69.68	65.50

Table 4. Average Precision in 3D View

Table 4.는 3D 시점에서의 AP 결과이다. SAV 기법을 적용할 경우, PointPillars[10]는 이번에도 모든 Class에 대해 큰 하락폭을 보였으며, SECOND[8]는 Pedestrian과 Cyclist의 성능이 하락하며, Car는 소폭 상향되었다. PV-RCNN[9] 및 MVX-Net[17]은 BEV에서와 비슷하게 Pedestrian에서의 성능이 높아졌고, Cyclist 및 Car에서의 성능이 낮아지게 되었다. 마지막으로 Part-A2[18]는 Pedestrian에서의 성능 하락, Cyclist 및 Car는 일부 결과 값은 하락하나 대체로 향상된 결과를 가진다.

다음 결과들의 핵심은, SAV를 적용하면 기법을 적용하지 않은 원본에 비해

객체 처리가 이뤄지는 시간이 작은 지연이 존재하지만, 성능에 큰 영향을 줄 정도의 차이는 없으며, 특히 PV-RCNN[9] 및 MVX-Net[17]에서의 작은 객체(보행자)에 대한 인식 성능이 크게 향상 되었다. 이에 따라, SAV 기법이 보편적으로 모든 상황에서 성능을 크게 높여주진 않았으나, 본 논문의 목적인 3D 객체 인식에서 세밀한 인식을 돕는 기법을 적용하면 작은 객체 인식에 도움이 된다는 점에 효과가 어느 정도 입증되어 향후 개선 여지가 있음을 확인하였다.

제 5장 결 론

5.1 결과 고찰 및 분석

본 연구는 Self-Adaptive Voxelization(SAV) 기법을 적용하여 3D 객체 인식을 진행하는 기존 Voxel 기반 CNN 모델의 성능을 분석하였다. 실험 결과를 바탕으로 각 기법의 효과와 한계를 다음과 같이 정리하였다.

PointPillars[10]와 SECOND[8]는 각각 2D · 3D 기반의 고정된 Voxel Grid 구조에 대한 연산이 최적화된 모델이므로, 정해진 해상도의 Feature 추출에 중점을 두고 설계되었다. Pillar 기반 모델에서의 실험 결과, 높은 성능 저하가 나타나게 되었는데, 이는 XY 평면만을 중심으로 한 2차원에서의 변형이 3차원의 경우보다 성능에 큰 영향을 끼치므로 이에 신중한 설계가 필요하다는 점이 시사되었다. 이에 따라, SAV의 동적 조정은 고정된 Grid에 최적화된 연산을 진행하는 모델에 유의미한 결과를 나타내지 못해 새로운 적응형 접근법이나 기법의 개선 방법 등이 필요하다고 분석하였다.

PV-RCNN[9]과 MVX-Net[17]은 SAV 기법의 주요 목표, 세밀한 객체 인식을 잘 나타낸 모델이다. PV-RCNN[9]은 Point Cloud와 Voxel 기반 특징 학습을 결합한 구조로 세밀한 Feature 추출에 강점을 가지며, MVX-Net[17]은 LiDAR와 RGB 데이터를 결합한 멀티 뷰 모델이다. 이러한 두 모델의 구조적 특성과 SAV 기법의 조합은 작은 객체 인식에 유리하게 작용한 것으로 관찰되며, 그로 인해 Pedestrian에서의 성능이 매우 높게 나타났다. Cyclist와 같은 중간 크기 객체는 Pedestrian보다 많고 Car보다 적은 점을 포함하여 Voxel 크기를 조정에 최적의 크기로 나타내기 어려워 성능이 낮

아지는 것으로 보인다.

Part-A2[18]는 Part-aware 구조를 통해 객체의 세부 부분을 학습하는 방식으로 설계 되었으나, SAV 기법이 Part-aware와 중복된 역할을 수행하여 Pedestrian 객체의 세부 조정에서 정보 손실이 발생한 것으로 보인다. 다만, Cyclist와 Car 같이 세부 조정의 영향이 상대적으로 적은 객체에는 성능 저하 없이 유사하거나 약간 향상된 결과를 나타냈다.

결론적으로, Self-Adaptive Voxelization 기법은 미리 설정된 크기의 Grid로 Point Cloud 데이터를 정렬하는 방식의 모델보다 객체의 밀도, 크기, 위치에 따른 유연한 데이터 표현을 지원하는 데이터의 특성 및 다양성을 반영하는 구조의 모델에 적합하며, 이는 특히 작은 객체 인식에서의 강점을 보이는 적응형 동적 조정 기법이다.

5.2 추후 연구

본 연구는 기존의 Voxel 기반 CNN 모델들이 세밀한 인식을 진행하여 성능을 향상시킬 수 있는 SAV 기법의 가능성 및 확장성을 확인하였다. 이에 대해, 향후 연구를 진행하게 된다면 PV-RCNN[9]과 MVX-Net[17]에서 한계를 보이던 중간 크기 객체(Cyclist)의 성능 하락 문제를 개선하기 위해 적합한 Voxel 크기 조정 방안 모색을 진행하고, SAV 기법이 PointPillars[10], SECOND[8]와 같은 고정된 Grid 분할에 최적화된 연산 모델과의 상성을 강화하며, KITTI Dataset[15] 외에도 다양한 데이터에서 효과적으로 기법을 적용할 수 있도록 기법을 고도화해 LiDAR 기반의 자율 주행 및 딥러닝 기술의 성능 향상에 기여하고자 한다.

참고 문헌

[1] C. R. Qi, H. Su, K. Mo, and L. J. Guibas, "PointNet: Deep learning on point sets for 3D classification and segmentation," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Honolulu, HI, USA, Jul. 2017, pp. 77–85.

[2] W. Shi and R. Rajkumar, "Point-GNN: Graph neural network for 3D object detection in a point cloud," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Seattle, WA, USA, Jun. 2020, pp. 1711–1720.

[3] A. Vaswani et al., "Attention is all you need," in Adv. Neural Inf. Process. Syst. (NeurIPS), Long Beach, CA, USA, Dec. 2017, pp. 5998–6008.

[4] Y. Zhou and O. Tuzel, "VoxelNet: End-to-end learning for point cloud based 3D object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Salt Lake City, UT, USA, Jun. 2018, pp. 4490–4499.

[5] Z. Liu et al., "A ConvNet for the 2020s," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), New Orleans, LA, USA, Jun. 2022, pp. 11976–11986.

[6] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Las Vegas, NV, USA, Jun. 2016, pp. 770–778.

[7] A. Dosovitskiy et al., "An image is worth 16x16 words: Transformers for image recognition at scale," in Proc. Int. Conf. Learn. Represent. (ICLR), Virtual Event, May 2021.

[8] Y. Yan, Y. Mao, and B. Li, "SECOND: Sparsely embedded convolutional detection," Sensors, vol. 18, no. 10, p. 3337, Oct. 2018.

[9] S. Shi et al., "PV-RCNN: Point-voxel feature set abstraction for 3D

object detection," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Seattle, WA, USA, Jun. 2020, pp. 10529–10538.

[10] A. H. Lang et al., "PointPillars: Fast encoders for object detection from point clouds," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Long Beach, CA, USA, Jun. 2019, pp. 12697–12705.

[11] G. Shi, R. Li, and C. Ma, "PillarNet: Real-time and high-performance pillar-based 3D object detection," arXiv preprint arXiv:2205.09411, May 2022.

[12] S. Zhou et al., "FastPillars: A deployment-friendly pillar-based 3D detector," arXiv preprint arXiv:2302.02383, Feb. 2023.

[13] Y. Zhou et al., "End-to-end multi-view fusion for 3D object detection in LiDAR point clouds," arXiv preprint arXiv:1910.06528, Oct. 2019.

[14] Z. Su et al., "DV-ConvNet: Fully convolutional deep learning on point clouds with dynamic voxelization and 3D group convolution," arXiv preprint arXiv:2009.03214, Sep. 2020.

[15] A. Geiger, P. Lenz, and R. Urtasun, "Are we ready for autonomous driving? The KITTI vision benchmark suite," in Proc. IEEE Conf. Comput. Vis. Pattern Recognit. (CVPR), Providence, RI, USA, Jun. 2012, pp. 3354–3361.

[16] K. Chen et al., "MMDetection: OpenMMLab detection toolbox and benchmark," arXiv preprint arXiv:1906.07155, Jun. 2019.

[17] V. A. Sindagi, Y. Zhou, and O. Tuzel, "MVX-Net: Multimodal VoxelNet for 3D object detection," in Proc. IEEE Int. Conf. Robot. Autom. (ICRA), Montreal, QC, Canada, May 2019, pp. 7276–7282.

[18] S. Shi et al., "From points to parts: 3D object detection from point

cloud with part-aware and part-aggregation network," IEEE Trans. Pattern Anal. Mach. Intell., vol. 43, no. 8, pp. 2647-2664, Aug. 2021.

[19] H. Caesar et al., "nuScenes: A multimodal dataset for autonomous driving," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Seattle, WA, USA, Jun. 2020, pp. 11621-11631.

[20] P. Sun et al., "Scalability in perception for autonomous driving: Waymo open dataset," in Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR), Seattle, WA, USA, Jun. 2020, pp. 2446-2454.

[21] A. Paszke et al., "PyTorch: An imperative style, high-performance deep learning library," in Adv. Neural Inf. Process. Syst. (NeurIPS), Vancouver, BC, Canada, Dec. 2019, pp. 8024-8035.

[22] OpenMMLab, "MMDetection3D," GitHub Repository. [Online]. Available: https://github.com/open-mmlab/mmdetection3d

Abstract

Adaptive Voxelization Techniques for Improved Precision in LiDAR-Based Object Detection

Ko, Dae Kwon
Dept. of Automotive Engineering
Gradate School of Hanyang University

This paper proposes a novel adaptive voxel adjustment technique to improve the accuracy of LiDAR-based 3D object detection. LiDAR sensors in 3D object detection are advantageous in recognizing long distances or object directions, but have limitations in that they are difficult to recognize in detail in areas with low point density or small objects. To solve this problem, we introduce the Self-Adaptive Voxelization (SAV) technique, which dynamically adjusts the voxel size based on the point density inside the voxel and the relative distance from the voxel center.

SAV efficiently collects and defines information inside the voxel, performs normalization, and balances the voxel size by adjusting it so that it does not change drastically through the Scaling Factor, and allocates an appropriate voxel size according to the density and relative distance inside the voxel to perform detailed and efficient feature extraction.

In order to directly implement the idea of this paper and examine its performance, we applied the SAV technique to PointPillars, SECOND, PV-RCNN, MVX-Net, and Part-A2 models using the KITTI dataset and the MMDetection3D open source framework, and compared their performance with the original models. As a result of the following experiments, PV-RCNN and MVX-Net showed significant improvements in recognition performance for small objects, demonstrating good performance for detailed object detection. However, models that perform operations based on a fixed 2D Grid structure, such as PointPillars, showed performance degradation, and PV-RCNN and MVX-Net, which showed positive performance, showed limitations in that their performance was lowered for medium-sized objects (Cyclist).

In conclusion, the Self-Adaptive Voxelization technique is a method that effectively improves recognition performance for small objects by flexibly adjusting the voxel size according to the density and size of the object. However, as a point to note, we selected factors that should consider the limitations shown in the experimental results, and selected the following for future research. We plan to expand the versatility of the Self-Adaptive Voxelization technique by improving performance for medium-sized objects, enhancing compatibility with fixed grid-based models, and verifying applicability to various datasets.

감사의 글

대학원 면접 결과가 나오기 전까지, 내가 원하는 목표를 세우고 온전히 이룰 수 있을까 하는 마음과 실패에 대한 두려움과 불안감이 들 무렵, 한양대학교 대학원 면접에 합격하게 되었다는 문자 알림이 아직도 또렷하게 기억이 나곤 합니다. 많은 대학원의 컨택 및 면접 실패로 인해 저 자신에 대한 자신감이 많이 낮아졌던 상황이었고, 이에 새로운 기회를 주신 박장현 지도교수님께 감사의 인사를 드리고 싶습니다. 제가 하고 싶었던 새로운 분야를 연구할 수 있도록 기회를 주시고, 격려해주셔서 이 자리까지 올 수 있게 되었습니다. 결과적으로 대학원 과정을 통해 원하는 분야를 연구하고 미래의 목표 및 방향성을 설정하는데 큰 도움이 되었습니다.

대학원 석사과정으로 연구실 생활을 시작할 무렵, 학부 전공과 관련이 적은 새로운 분야를 석사 전공 과정으로 진행하여 목표를 삼고 진행하는 것은 저에게 어려운 일이었고 큰 도전이었습니다. 기본적인 석사 전공 지식이 갖춰지지 않은 상태에서 새로운 개념을 이해하거나, 배우는 속도도 빠르지 않아 능숙하지 않은 상태에서의 공부는 그리 순탄하지 않았고, 그럴 때마다 도움을 주신 지능기계연구실 인원들이 있었습니다. 지금까지 친절히 도와주신 연구실 인원 모두에게도 감사의 말을 전합니다. 연구실의 상황이나 모르는 정보를 알려주시고 많이 도와주시던 우리들의 랩장 태연이형, 모르는 개념에 대해 쉽고 자세히 알려주시고, 친근하게 대해주셔서 편하고 좋았던 영훈이형, 대학원이 처음이라 곤란하던 저에게 여러 가지 정보랑 팁을 제시해주시고 도와주신 용식이형, LiDAR 센서에 관해 가장 많은 정보를 제공해주시고 전공 공부에 큰 도움을 주신 우영 선배님, 내가 부족한 부분을 도와주고 성심성의껏 열심히 연구실 생활에 임하던 성우까지 우리 연구실 인원들에게 모두 감사의 인사를 드

립니다. 지금은 졸업했지만 신입생 당시 모르는 점을 친절하게 알려주거나 연구실 분위기를 즐겁게 만들고 조언을 해준 도영이, 신입생 시절의 저를 많이 격려해주고 도와주던 승혁이 형에게도 감사의 마음을 전합니다.

또한, 졸업을 앞두게 된 지금의 자리에 오기 전까지 아낌없는 지지와 믿음을 보내주신 제가 가장 사랑하는 가족과 여자친구에게도 감사의 말을 전하고 싶습니다. 대학원이라는 길을 선택할 때 아낌없는 지지와 도움을 주신 우리 엄마, 아빠, 그리고 동생 덕분에 무사히 석사 과정을 마칠 수 있었습니다. 이제 사회에서나 가정에서나 항상 든든하고 자랑스러운 아들, 맏이로써 가족들을 단단하게 버텨주는 기둥이 되겠습니다. 그리고, 2년 동안 결코 짧지 않은 시간 동안 저를 믿어주고, 응원하고, 항상 즐겁게 지내면서 옆에 있어준 제 여자친구 미선이가 있어 힘든 대학원 생활을 끝까지 버텨내고 무사히 연구 결과물을 낼 수 있었다고 생각합니다. 거리가 멀어 자주 보진 못했지만 마음은 아주 가까운 동반자로써 내가 열심히 할 명분을 주었던, 그런 열정적인 목표이자 동기부여를 설정하게 해주어 고맙고, 사랑합니다.

2년이라는 시간이 길고 긴 시간을 통해 다양한 경험을 하고 원하는 전공 분야에서의 연구를 수행한 이 시간이 저에게는 아주 중요한 터닝 포인트가 되었습니다. 앞으로도 열심히 노력하여 사회에 진출하고 열심히 제 뜻을 이뤄보겠습니다.

2024년 12월 정몽구 미래자동차연구센터 지능기계연구실에서

고 대 권

연구 윤리 서약서

본인은 한양대학교 대학원생으로서 이 학위논문 작성 과정에서 다음과 같이 연구 윤리의 기본 원칙을 준수하였음을 서약합니다.

첫째, 지도교수의 지도를 받아 정직하고 엄정한 연구를 수행하여 학위논문을 작성한다.

둘째, 논문 작성시 위조, 변조, 표절 등 학문적 진실성을 훼손하는 어떤 연구 부정행위도 하지 않는다.

셋째, 논문 작성시 논문유사도 검증시스템 "카피킬러"등을 거쳐야 한다.

2024년12월17일

학위명 : 석사

학과 : 미래자동차공학과

지도교수 : 박장현

성명 : 고대권 (서명)

한 양 대 학 교 대 학 원 장 귀 하

Declaration of Ethical Conduct in Research

I, as a graduate student of Hanyang University, hereby declare that I have abided by the following Code of Research Ethics while writing this dissertation thesis, during my degree program.

"First, I have strived to be honest in my conduct, to produce valid and reliable research conforming with the guidance of my thesis supervisor, and I affirm that my thesis contains honest, fair and reasonable conclusions based on my own careful research under the guidance of my thesis supervisor.

Second, I have not committed any acts that may discredit or damage the credibility of my research. These include, but are not limited to : falsification, distortion of research findings or plagiarism.

Third, I need to go through with Copykiller Program(Internet-based Plagiarism-prevention service) before submitting a thesis."

DECEMBER 17, 2024

Degree :	Master
Department :	DEPARTMENT OF AUTOMOTIVE ENGINEERING
Thesis Supervisor :	Jahng-Hyon Park
Name :	KO DAE KWON (Signature)